

Modelos Substitutos Regionais como Guia para Otimização de Raciocínio Abduativo no Diagnóstico Clínico

Ermeson José Ribeiro Ferreira Instituto Federal de Educação, Ciência e Tecnologia do Ceará - IFCE
Programa de Pós-Graduação em Ciência da Computação

Fortaleza, CE, Brasil

ribeiro.ermeson07@aluno.ifce.edu.br

Prof. Dr. Thiago Alves Rocha Instituto Federal de Educação, Ciência e Tecnologia do Ceará - IFCE
Departamento de Ciência da Computação

Fortaleza, CE, Brasil

thiago.alves@ifce.edu.br

Abstract—Explicações baseadas em lógica formal, como as Explicações Abduativas (AXps), oferecem garantias matemáticas rigorosas para modelos de Aprendizado de Máquina, o que é crucial para áreas de alto impacto, como a medicina computacional. No entanto, computar essas explicações exatas diretamente a partir de modelos complexos ocasiona uma explosão combinatória exponencial (problema *NP-hard*), dificultando o suporte à decisão clínica em tempo real. Este artigo propõe uma nova estrutura neuro-simbólica que aborda esse gargalo de escalabilidade por meio do particionamento geométrico e da destilação de modelo. Ao destilar um modelo *XGBoost* de considerável desempenho do tipo “caixa-preta” em uma árvore de decisão substituta rasa e linear por partes, a arquitetura proposta atua como um filtro geométrico que restringe o espaço de busca local. As restrições de fronteira resultantes são então inseridas no *solver Z3 SMT*, que atua como um oráculo formal otimizado para provar e extrair explicações parcimoniosas. Avaliada com o conjunto de dados *UCI Heart Disease*, a estrutura alcançou uma fidelidade de substituição de 80,22%, reduzindo com sucesso a explicação a uma explicação abduativa mínima (AXp) de apenas quatro características clínicas críticas. Fundamentalmente, o oráculo formal filtrou ruídos estatísticos globais (como idade e colesterol) que eram supervalorizados por métricas tradicionais de importância de características, fornecendo uma justificativa diagnóstica verificada, logicamente válida e enxuta, adequada para auditoria médica.

I. INTRODUÇÃO

A. Contexto e Motivação

Modelos baseados em redes neurais artificiais e conjuntos de árvores são amplamente utilizados para a realização de aprendizado de máquina em diversas aplicações cotidianas. Assim, nos últimos anos, algoritmos baseados em dados, como o *XGBoost*, consolidaram-se como o estado da arte para previsões clínicas e diagnósticos tabulares, tais como a previsão de risco cardiovascular e a detecção de diabetes.

Contudo, o sucesso preditivo desses métodos esbarra em sua natureza opaca. Por funcionarem como modelos “caixa-preta”, geralmente não é possível compreender precisamente qual conhecimento a estrutura interna utilizou para alcançar uma determinada decisão.

Em se tratando da tomada de decisão no contexto da medicina computacional, a interpretabilidade não é apenas um detalhe adicional, mas um requisito ético, legal e de segurança

para o suporte à decisão em tempo real [2]. Assim, em áreas de alta criticidade, é fundamental que as previsões adotadas sejam passíveis de validação por especialistas humanos.

B. Os Limites da Inteligência Artificial Explicável Atual

No cenário atual da Inteligência Artificial Explicável (XAI), geralmente empregam-se abordagens estatístico-heurísticas (como os Modelos Substitutos Locais e Regionais) ou abordagens formais (como a lógica abduativa) para a extração do conhecimento utilizado pelo modelo. No entanto, de forma isolada, ambas as vertentes mostram-se insuficientes para resolver completamente o problema, que possui natureza complexa e limitações em aberto na literatura.

Enquanto os modelos regionais segregam o espaço de dados em sub-regiões interpretáveis para aproximar o comportamento do classificador global [5] — podendo falhar na fidelidade fina próximo às fronteiras de decisão dessas regiões —, a lógica abduativa oferece consistência lógica rigorosa e causalidade para inferir as hipóteses necessárias [1]. Contudo, o método formal sofre com a explosão combinatória e o alto custo computacional, tornando-se inviável para bases de dados complexas e modelos volumosos [3].

C. Contribuição Proposta

Considerando o cenário de previsão de diagnósticos clínicos, emerge um dilema crítico: os profissionais de saúde necessitam de explicações que sejam, simultaneamente, semanticamente ricas (rigorosas) e computacionalmente eficientes (rápidas) para o suporte à decisão em tempo real. Para solucionar esse impasse, este trabalho propõe uma abordagem híbrida original que une a flexibilidade estatística dos modelos regionais à robustez determinística da lógica formal.

Assim, em vez de tentar codificar todo o complexo modelo *XGBoost* dentro de um *solver* lógico, o *framework* introduz uma árvore de decisão substituta (*Surrogate Tree*) que atua como um “funil geométrico”. Essa árvore pré-particiona o espaço de busca, isolando as sub-regiões locais de decisão. A lógica abduativa (oráculo formal via *Z3*) é então acionada de forma direcionada apenas sobre as inequações lineares simples

geradas por aquela partição específica da árvore, mitigando o custo computacional global.

Portanto, propõe-se a investigação de uma arquitetura neuro-simbólica entre a IA Baseada em Dados e a IA Baseada em Conhecimento. Ao utilizar o modelo regional para guiar o escopo da abdução, a pesquisa propõe uma solução original para o problema aberto de escalabilidade de métodos formais em *XAI*, demonstrando que a união desses paradigmas explicativos [6] é um caminho promissor para alcançar explicabilidade com rigor científico e viabilidade prática na medicina computacional.

II. TRABALHOS RELACIONADOS

A fundamentação teórica deste trabalho combina três pilares principais da Inteligência Artificial Explicável (*XAI*): os modelos substitutos regionais, as explicações formais baseadas em abdução e a destilação lógica de modelos opacos.

A. Modelos Substitutos Regionais e Locais

Os modelos substitutos (*surrogate models*) são amplamente utilizados para aproximar o comportamento de caixas-pretas através de estruturas intrinsecamente interpretáveis. Enquanto abordagens globais tentam abranger o modelo inteiro, abordagens locais e regionais focam em partições específicas do espaço de características (*features*).

A fundamentação para o particionamento do espaço baseia-se em conceitos como os propostos por [5], que exploram modelos regionais para a identificação de sistemas não-lineares complexos através de segmentações geométricas.

No contexto de *XAI* tabular, revisões abrangentes como a de [2] apontam que, embora os métodos regionais ofereçam alta eficiência computacional e facilidade de extração de regras, eles carecem de garantias lógicas formais, introduzindo imprecisões e instabilidades próximo às fronteiras de decisão das folhas ou partições.

B. Explicações Formais Baseadas em Abdução

Para superar a falta de rigor matemático dos métodos estatísticos, uma vertente recente de pesquisa foca em explicações logicamente garantidas. O trabalho pioneiro de Ignatiev, Narodytska e Marques-Silva [1] introduziu formalmente as Explicações Abdutivas (*AXps*), definindo-as como o menor subconjunto suficiente de características (*Minimal Sufficient Subset*) capaz de garantir deterministicamente uma predição local.

Embora conceitualmente robusto, o mapeamento direto de modelos estatísticos para *solvers* SMT sofria com gargalos de escalabilidade. Tentativas de aplicar essa lógica diretamente a modelos baseados em árvores de decisão complexas, como o *Gradient Boosting* e *XGBoost*, demonstraram que o custo computacional de codificar múltiplos conjuntos de árvores gera uma explosão combinatória severa [3].

Diferente de abordagens que tentam otimizar a velocidade da abdução puramente via seleção automatizada de algoritmos de busca lógica, como explorado por [4] no contexto de diagnóstico médico tradicional, a presente pesquisa lida com o gargalo na origem, reduzindo o tamanho do problema lógico que é enviado ao *solver*.

C. Destilação Lógica Neuro-Simbólica

A convergência entre o aprendizado estatístico e o raciocínio simbólico tem gerado a necessidade de traduzir representações matemáticas contínuas em lógica discreta. Este processo é conhecido na literatura como Destilação Lógica (*Logical Distillation*).

Recentemente, Pluska et al. [6] demonstraram o sucesso dessa abordagem ao realizar a destilação lógica de Redes Neurais em Grafos (*GNNs*), provando que modelos altamente complexos e não-lineares podem ter suas topologias de decisão extraídas na forma de fórmulas lógicas simplificadas sem perda catastrófica de desempenho.

O presente trabalho alinha-se a essa vanguarda neuro-simbólica, mas inova ao utilizar a Árvore Substituta não apenas como o modelo final explicativo, mas como um filtro geométrico prévio que viabiliza a aplicação de um *solver* Z3 formal em tempo de execução clínica.

III. BACKGROUND E FUNDAMENTAÇÃO TEÓRICA

Esta seção apresenta os conceitos matemáticos e lógicos que servem de base para o framework proposto, cobrindo o formalismo de satisfatibilidade e as definições formais de explicabilidade lógica.

A. Teorias do Módulo da Satisfatibilidade (SMT)

O problema clássico de Satisfatibilidade Booleana (SAT) consiste em determinar se existe uma atribuição de valores booleanos capaz de tornar uma fórmula proposicional verdadeira. Embora o problema SAT seja suficiente para representar diversas tarefas de decisão, muitas aplicações em Inteligência Artificial, verificação formal e síntese de programas exigem o tratamento de restrições envolvendo estruturas matemáticas mais expressivas, como números inteiros e reais, vetores de bits, *arrays* e funções. Para esse propósito, foi desenvolvido o formalismo das Teorias do Módulo da Satisfatibilidade (SMT), que estende o SAT incorporando teorias de primeira ordem decidíveis [7].

Formalmente, seja uma fórmula lógica φ construída sobre um conjunto de variáveis booleanas e variáveis pertencentes a uma teoria T . O problema SMT consiste em decidir se existe uma interpretação que satisfaça simultaneamente as restrições proposicionais e os axiomas da teoria considerada. Diferentemente do SAT, no qual todas as variáveis assumem apenas valores verdadeiro ou falso, um problema SMT pode conter variáveis aritméticas reais ou inteiras sujeitas a restrições lineares e não-lineares, tais como:

$$x + y > 10, \quad 2x - y = 5, \quad x \geq 0 \quad (1)$$

Assim, um modelo satisfatório deve atender simultaneamente à estrutura lógica da fórmula e às restrições matemáticas impostas pela teoria.

Os *SMT solvers* automatizam esse processo combinando algoritmos eficientes para SAT com procedimentos específicos para cada teoria lógica. Entre os solucionadores mais utilizados destaca-se o Z3, que integra mecanismos de propagação booleana, geração de conflitos e solucionadores especializados

para aritmética linear, *bit-vectors*, *arrays* e funções [8]. Dado um conjunto de restrições Φ , um *solver* retorna um dos seguintes resultados:

- **SAT:** quando existe ao menos um modelo que satisfaz todas as restrições;
- **UNSAT:** quando nenhum modelo satisfaz simultaneamente todas as restrições.

Esses estados permitem realizar verificação formal de propriedades matemáticas. Em particular, para provar que uma propriedade P é válida, verifica-se a satisfatibilidade de sua negação $\neg P$. Caso o *solver* retorne UNSAT, conclui-se que $\neg P$ é inconsistente e, portanto, P é necessariamente verdadeira. Essa estratégia constitui uma das bases da verificação automática de modelos de Inteligência Artificial.

B. Explicações Abdutivas Formais (AXps)

Nos últimos anos, métodos de Inteligência Artificial Explicável (XAI) têm buscado fornecer justificativas formais para decisões produzidas por modelos de aprendizado de máquina. Entre as abordagens baseadas em lógica, as Explicações Abdutivas (AXps) destacam-se por caracterizar explicações como subconjuntos mínimos de características suficientes para preservar a predição do modelo [1].

Considere um modelo de classificação:

$$f : \mathcal{X} \rightarrow \mathcal{Y} \quad (2)$$

em que $\mathcal{X}$ representa o espaço de entrada e $\mathcal{Y}$ o conjunto de rótulos possíveis. Seja uma instância $x = (x_1, x_2, \dots, x_n) \in \mathcal{X}$, cuja classificação é dada por $f(x)$.

Uma explicação abdutiva é construída a partir da identificação de um subconjunto de atributos cuja fixação é suficiente para garantir que qualquer outra instância compatível produza a mesma classificação. Formalmente, seja $\mathcal{M} \subseteq \{1, \dots, n\}$ um subconjunto de índices correspondente às características preservadas. Diz-se que $\mathcal{M}$ é uma explicação abdutiva (AXp) [1] quando satisfaz a seguinte implicação:

$$\forall z \in \mathcal{X}, \left(\bigwedge_{i \in \mathcal{M}} (z_i = x_i) \right) \implies f(z) = f(x) \quad (3)$$

Essa definição estabelece que qualquer instância z que preserve os valores das características pertencentes a $\mathcal{M}$ necessariamente recebe a mesma classificação atribuída à instância original. Além disso, o subconjunto deve ser minimal, isto é, nenhum subconjunto próprio de $\mathcal{M}$ continua satisfazendo essa propriedade.

A busca por AXps pode ser formulada diretamente como um problema de satisfatibilidade. Intuitivamente, procura-se verificar se existe alguma instância alternativa que mantenha fixas as características de $\mathcal{M}$ e produza uma classificação diferente ($f(z) \neq f(x)$). Caso tal instância não exista, o *solver* retorna UNSAT, demonstrando formalmente que o conjunto de atributos considerado é suficiente para explicar a decisão do modelo.

A verificação de que um subconjunto de atributos constitui uma AXp requer demonstrar que não existe qualquer instância compatível que altere a predição do modelo. Na prática, essa

propriedade implica a exploração exaustiva de um espaço de busca exponencial no número de atributos (2^n), tornando a geração de explicações minimais de cardinalidade ótima um problema computacionalmente desafiador e pertencente à classe de complexidade NP-hard [3]. Desse modo, o gargalo de escalabilidade dos métodos formais puros exige arquiteturas híbridas capazes de mitigar a dimensão desse espaço de busca antes da ativação do *solver*.

C. Destilação de Conhecimento e Modelos Substitutos

O conceito de Destilação de Conhecimento (*Knowledge Distillation*), originalmente introduzido no contexto de compressão de redes neurais, fundamenta-se na transferência de comportamento de um modelo complexo e de alta capacidade — denominado modelo Professor (*Teacher*) — para um modelo estruturalmente mais simples e interpretável — denominado modelo Aluno (*Student*) [6].

Formalmente, seja $f : \mathcal{X} \rightarrow \mathcal{Y}$ o modelo caixa-preta (como um *ensemble* do *XGBoost*) que atua como o Professor. O objetivo da destilação para fins de explicabilidade é treinar um modelo substituto global ou regional (*surrogate model*) $g : \mathcal{X} \rightarrow \mathcal{Y}$, pertencente a uma classe de modelos intrinsecamente interpretáveis (como árvores de decisão rasas), tal que g mimetize a função de mapeamento de f . O treinamento do modelo Aluno é guiado pela minimização de uma função de perda empírica sobre as predições geradas pelo próprio Professor:

$$\min_{\theta} \sum_{i=1}^N \mathcal{L}(f(x_i), g(x_i; \theta)) \quad (4)$$

onde θ representa os parâmetros do modelo substituto e $\mathcal{L}$ é uma métrica de divergência aplicável.

A qualidade de um modelo substituto é avaliada através da sua Fidelidade ($\mathcal{F}$), que mede a capacidade do modelo Aluno de reproduzir fielmente as decisões do modelo caixa-preta no espaço de dados testado, definida por:

$$\mathcal{F} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(f(x_i) = g(x_i)) \quad (5)$$

onde $\mathbb{I}$ é a função indicadora que assume valor 1 se as predições forem idênticas e 0 caso contrário.

No subespaço delimitado por modelos regionais, o modelo g decompõe o espaço de características contínuas em partições lineares por partes. Embora esses substitutos suavizem as fronteiras micro-complexas do modelo original (atuando como um filtro de ruído), eles oferecem a estrutura matemática simplificada necessária para que métodos formais de verificação operem sem o fardo da complexidade global do modelo f .

IV. ARQUITETURA PROPOSTA

Esta seção detalha a arquitetura do *framework* híbrido desenvolvido para a extração de explicações formais locais em tempo de execução clínica. A abordagem proposta atenua a barreira computacional clássica da abdução lógica por meio de um processo estruturado em três estágios principais: predição de alto desempenho, destilação geométrica local e checagem de modelos via satisfatibilidade lógica.

A. Visão Geral do Framework

O fluxo da solução proposta opera de maneira sequencial. Inicialmente, o sistema recebe como entrada uma instância clínica $x \in \mathcal{X}$ proveniente do *UCI Heart Disease Dataset*, acompanhada pelas matrizes de limites globais da base de dados (X_{ranges}). Conforme ilustrado no pipeline do sistema, esses dados alimentam o modelo Professor, implementado através de um *ensemble* de árvores *XGBoost*, responsável por computar a predição diagnóstica de alta capacidade discriminatória $f(x)$.

Embora o conhecimento preditivo de $f(x)$ seja robusto, a aplicação direta da lógica abdutiva clássica sobre o *ensemble* global geraria um crescimento computacional exponencial (*NP-hard*), inviabilizando o suporte à decisão médica em tempo real [3].

Para contornar esse gargalo, o *framework* introduz uma etapa intermediária de filtragem: antes de acionar o raciocínio formal, o espaço de busca de hipóteses é suavizado por meio de um particionamento geométrico regional, delimitando o escopo do problema lógico.

B. Particionamento Geométrico via Surrogate Regional

O segundo estágio consiste no processo de destilação de conhecimento lógico. Utilizando as predições geradas pelo modelo Professor $f(x)$, treina-se uma Árvore de Decisão rasa que atua como o modelo Aluno substituto (*Surrogate Tree*) $g(x)$. Diferentemente de uma árvore tradicional treinada sobre os rótulos originais do *dataset*, o modelo $g(x)$ é otimizado para mimetizar estritamente o comportamento de fronteira do *XGBoost*.

Uma vez validada a fidelidade local do modelo Aluno, a instância alvo x é mapeada dentro da estrutura de $g(x)$ para identificar a folha específica de decisão na qual o paciente foi classificado. Esse nó folha encapsula um conjunto finito de decisões lineares por partes. Programaticamente, o *framework* extrai os limiares (*thresholds*) e as variáveis testadas ao longo do caminho de decisão da raiz até a referida folha, gerando uma conjunção de restrições geométricas lineares que definem o subespaço local do paciente.

C. O Oráculo Abutivo Otimizado via Z3

A etapa final realiza a validação formal do subconjunto candidato de atributos utilizando o *solver* SMT Z3 como um oráculo determinístico. Para determinar se um subconjunto de características $\mathcal{M}$ constitui uma explicação abdutiva (AXp), o *framework* executa um algoritmo de busca gulosa por eliminação reversa (*backward elimination*), detalhado no Algoritmo 1.

O funcionamento do oráculo fundamenta-se na busca por contraexemplos dentro do subespaço linear delimitado pela folha. O *solver* Z3 é instanciado e recebe a fixação dos valores numéricos das características contidas no subconjunto de teste $\mathcal{T}$. Em seguida, injeta-se a negação da conjunção de regras que definem a folha ($\neg \text{regras_folha}$).

Se o Z3 retornar UNSAT, prova-se matematicamente que é impossível encontrar qualquer ponto no espaço que mantenha os atributos de $\mathcal{T}$ fixos e consiga escapar daquela região

Algorithm 1 Busca Gulosa para Abdução Otimizada via Z3

Require: Modelo Aluno g , Instância x , Ranges Globais X_{ranges}

Ensure: Subconjunto Mínimo Suficiente $\mathcal{M}$

- 1: $\mathcal{M} \leftarrow \{1, 2, \dots, n\}$ {Inicializa com todas as características}
- 2: $\text{regras_folha} \leftarrow \text{ExtraireRestricoesFolha}(g, x)$
- 3: **for** cada característica $f \in \mathcal{M}$ **do**
- 4: $\mathcal{T} \leftarrow \mathcal{M} \setminus \{f\}$ {Subconjunto candidato de teste}
- 5: $S \leftarrow \text{CriarSolverZ3}()$
- 6: $\text{FixarVariaveisSimbolicas}(S, x, \mathcal{T})$
- 7: $\text{AdicionarLimitesEspaco}(S, X_{\text{ranges}})$
- 8: $S.\text{add}(\neg \text{regras_folha})$ {Injeta a negação da invariância local}
- 9: **if** $S.\text{check}() == \text{UNSAT}$ **then**
- 10: $\mathcal{M} \leftarrow \mathcal{T}$ {Característica f é dispensável; atualiza a AXp}
- 11: **end if**
- 12: **end for**
- 13: **return** $\mathcal{M}$

geométrica de decisão. Portanto, a exclusão da característica f é segura e o subconjunto permanece suficiente. Caso retorne SAT, o *solver* expõe um contraexemplo real no qual a predição seria alterada, forçando o algoritmo a reter a característica avaliada para garantir a blindagem lógica do diagnóstico final.

V. CONFIGURAÇÃO EXPERIMENTAL

Este capítulo descreve o ecossistema experimental concebido para avaliar o *framework* neuro-simbólico proposto, detalhando as propriedades do conjunto de dados, as parametrizações dos modelos e os critérios de avaliação adotados.

A. Descrição do Conjunto de Dados

Para a validação empírica da arquitetura, utilizou-se o clássico *UCI Heart Disease Dataset*. O conjunto de dados é composto por 303 instâncias clínicas e armazena 13 características preditivas (*features*) de natureza tabular, além do rótulo binário correspondente à presença ou ausência de cardiopatia coronariana.

A escolha do domínio cardiológico justifica-se pelo fato de cenários de suporte à decisão médica demandarem alta fidelidade explicativa, nos quais a garantia formal de suficiência determinística apresenta maior valor clínico do que correlações estatísticas puras. Adicionalmente, a opção por essa base pública e consolidada viabiliza a reprodutibilidade dos testes sem violar restrições éticas ou leis de privacidade e proteção de dados, dado o anonimato estrito dos registros.

B. Configurações dos Modelos e Ambiente Experimental

O processo de indução dos classificadores foi estruturado sob a filosofia de destilação de conhecimento, dividindo-se entre os modelos Professor e Aluno:

- **Modelo Professor (f):** Implementou-se um classificador *XGBoost* (*Extreme Gradient Boosting*) configurado com um conjunto de 100 estimadores ($n_{\text{estimators}} = 100$), profundidade máxima limitada a três níveis ($\text{max_depth} = 3$), taxa de aprendizado estipulada em 0,1 ($\text{learning_rate} = 0,1$) e a entropia cruzada binária (logloss) como métrica de otimização de perda.
- **Modelo Aluno (g):** Como modelo substituto regional, instanciou-se uma Árvore de Decisão (*Decision Tree Classifier*) operando com a parametrização padrão, atuando de maneira a mimetizar localmente o comportamento do *XGBoost*.

Como divisão dos conjuntos de dados, aplicou-se a estratégia de amostragem *Hold-out*, segregando a base de dados na proporção de 70% para a etapa de treinamento e 30% para a fase de testes e avaliação do oráculo.

C. Métricas de Avaliação e Análise Comparativa

Para mensurar a eficácia da abordagem híbrida proposta, o experimento se apoia em três pilares analíticos principais:

- 1) **Mapeamento de Fidelidade Global e Local:** A aderência da destilação lógica é avaliada computando-se a acurácia de mimetismo (Fidelidade $\mathcal{F}$) e a matriz de confusão diretamente entre as previsões geradas pelo modelo Aluno em relação ao modelo Professor.
- 2) **Robustez Estatística por Validação Cruzada:** Para garantir que a amostragem não introduziu viés na indução das árvores, aplica-se o método de Validação Cruzada Estratificada com 5 partições e embaralhamento de dados (K -Fold com $k = 5$). O *score* de desempenho de generalização é mensurado comparativamente entre ambos os modelos.
- 3) **Discrepância Estatístico-Formal:** Por fim, realiza-se o levantamento da relevância global de atributos obtida por meio da métrica nativa de ganho do *XGBoost* (*Feature Importance*). Essa visão macro-estatística é colocada em paralelo e contrastada com o Subconjunto Mínimo Suficiente ($\mathcal{M}$) extraído pelo oráculo Z3 para instâncias específicas, evidenciando analiticamente a divergência entre métricas probabilísticas globais e garantias lógicas formais locais.

VI. RESULTADOS E DISCUSSÕES

Esta seção expõe os resultados empíricos obtidos pelo presente trabalho, estruturando a análise em torno da fidelidade da destilação, estabilidade estatística dos modelos e, fundamentalmente, na validação do oráculo abdutivo local em contraste com métricas estatísticas globais.

A. Análise de Fidelidade da Destilação Lógica

O primeiro critério de validação do *framework* reside na capacidade do modelo Aluno (g) de reproduzir fielmente as decisões tomadas pelo modelo Professor (f). O processo de destilação lógica alcançou uma Fidelidade Global de 80,22%. A distribuição detalhada desse mimetismo de comportamento pode ser observada na matriz de confusão da Figura 1.




Fig. 1. Matriz de Confusão medindo a Fidelidade entre o modelo caixa-preta (*XGBoost*) e o substituto (Árvore de Decisão).

A partir das 91 instâncias submetidas ao conjunto de teste, o modelo interpretável replicou com exatidão 37 previsões da classe negativa (0) e 36 previsões da classe positiva (1). Ocorreram apenas 18 divergências de classificação entre os modelos (10 falsos positivos e 8 falsos negativos em termos de fidelidade). Esse comportamento de aderência de aproximadamente 80% valida o uso da *Surrogate Tree* como um aproximador geométrico robusto, gerando partições locais lineares que preservam substancialmente as fronteiras originais do *XGBoost*.

B. Avaliação de Desempenho e Robustez Estatística

Para reduzir vieses de amostragem, realizou-se a validação cruzada estratificada em 5 partições (5-Fold) para avaliar o desempenho preditivo de ambos os classificadores em relação aos rótulos reais do *dataset*. Os resultados comparativos estão consolidados na Tabela I.

TABLE I
COMPARAÇÃO DE ACURÁCIA GERAL VIA VALIDAÇÃO CRUZADA (5-FOLD)

Modelo	Pontuações por Fold	Acurácia Média	Desvio Padrão (σ)
XGBoost (Mestre)	[0.88, 0.75, 0.73, 0.81, 0.83]	80,54%	0,0538
DT (Aluno)	[0.80, 0.77, 0.77, 0.65, 0.65]	72,88%	0,0654

Conforme esperado na literatura de destilação de conhecimento, observa-se uma pequena perda na acurácia média do modelo Aluno (72,88%) em comparação ao modelo Professor (80,54%). Esse fenômeno constitui o clássico *trade-off* entre interpretabilidade e poder preditivo. Contudo, o desvio padrão controlado ($\sigma = 0,0654$) comprova que a árvore substituta retém estabilidade estatística aceitável, viabilizando sua estrutura matemática para a extração de regras locais sem sofrer com subajuste (*underfitting*) catastrófico.

C. O Oráculo Z3: Importância Estatística Global vs. Su-ficiência Formal Local

A principal contribuição deste trabalho evidencia-se ao contrastar a relevância global de características obtida via *XGBoost* (*Feature Importance*, Figura 2) com a explicação lógica minimal local gerada pelo oráculo SMT Z3 para um paciente específico.




Fig. 2. Importância global de atributos calculada nativamente pelo *XGBoost*.

Ao avaliar heurísticamente a base de dados de forma global, o *XGBoost* elege a Idade (*age*, score 99.0) e o Colesterol (*chol*, score 78.0) como os fatores mais determinantes para as suas predições. Contudo, ao submeter o subespaço geométrico de um paciente com problemas cardíacos ao algoritmo de busca abdutiva, o *solver* Z3 revelou um cenário clínico local completamente distinto, executando o seguinte comportamento de poda:

- **Atributos Descartados (Poda Segura):** O oráculo retornou UNSAT para a eliminação de variáveis macros, como *age* (Índice 0) e *chol* (Índice 4). Isso constitui uma **prova matemática** de que, no subespaço local daquele paciente, flutuações na idade ou no colesterol são incapazes de alterar o diagnóstico.
- **Atributos Retidos (Bloqueio por Contraexemplo):** O *solver* encontrou estados SAT ao tentar remover os índices 1, 2, 3 e 11, expondo contraexemplos matemáticos onde a alteração desses valores reverteria o diagnóstico.

O resultado final determinou o seguinte subconjunto mínimo suficiente composto por apenas 4 variáveis críticas:

$$AXp = \{ca: 1.0, sex: 1.0, cp: 0.0, trestbps: 150.0\} \quad (6)$$

Esta discrepância revela o principal gargalo de métodos tradicionais de XAI (como mapas de saliência ou importâncias globais): um atributo altamente irrelevante para um paciente específico pode ser mascarado como importante devido ao comportamento macro do modelo. O ecossistema híbrido proposto, impulsionado pelo Z3, limpou com sucesso o ruído estatístico global (*age* e *chol*) e isolou deterministicamente

uma combinação clínica clássica de alto risco (Isquemia Silenciosa em paciente masculino e hipertenso com vaso obstruído), provando que o framework fornece explicações enxutas, parcimoniosas e com garantia lógica.

VII. CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho apresentou um *framework* neuro-simbólico que une a flexibilidade estatística dos modelos substitutos regionais ao rigor determinístico da lógica formal via solucionadores SMT. A arquitetura foi desenvolvida para mitigar o histórico gargalo de escalabilidade computacional que limita a aplicação prática de Explicações Baseadas em Abdução (*AXps*) em ambientes de alta criticidade, como a medicina computacional.

Os resultados experimentais obtidos a partir do *UCI Heart Disease Dataset* comprovaram a viabilidade da abordagem. O processo de destilação alcançou uma fidelidade de mimetismo de 80,22%, permitindo que a árvore substituta atuasse com sucesso como um "funil geométrico". Esse particionamento regional reduziu drasticamente a dimensão do espaço de busca linear, viabilizando que o *solver* Z3 operasse como um oráculo formal rápido em tempo de execução.

A relevância prática do método evidenciou-se no estudo de caso, no qual o oráculo Z3 foi capaz de isolar uma explicação parcimoniosa de apenas 4 atributos críticos para um paciente específico, eliminando variáveis de ruído macro-estatístico (como idade e colesterol) que haviam sido hipervalorizadas pela métrica global de *Feature Importance* do *XGBoost*. Desse modo, o *framework* provou fornecer justificativas clínicas logicamente válidas e semanticamente ricas, fundamentais para a auditoria de diagnósticos por especialistas humanos.

Como perspectivas para trabalhos futuros, sugerem-se as seguintes frentes de pesquisa:

- 1) **Expansão de Modelos Alunos:** Investigar o comportamento do oráculo formal utilizando outras classes de modelos substitutos locais linearmente particionados por partes, como os *Extreme Learning Machines* (ELM) ou Modelos Regionais Não-Lineares, avaliando o impacto na fidelidade de mimetismo.
- 2) **Abdução Probabilística e Incerteza:** Adicionar restrições de lógica probabilística ou lógica difusa (*fuzzy logic*) dentro do *solver* para lidar com a incerteza intrínseca e ruídos de medição comuns em exames e dados de prontuários médicos.
- 3) **Otimização Automática de Solvers:** Aplicar meta-heurísticas de seleção automatizada de algoritmos (*Algorithm Selection*) diretamente no motor do Z3, otimizando as heurísticas internas do solucionador SMT de acordo com a topologia geométrica da folha extraída.

REFERENCES

- [1] A. Ignatiev, N. Narodytska, and J. Marques-Silva, "Abduction-based explanations for machine learning models," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 33, no. 01, 2019, pp. 1511–1519.
- [2] D. Minh, H. X. Wang, Y. F. Li, and T. N. Nguyen, "Explainable artificial intelligence: a comprehensive review," *Artificial Intelligence Review*, vol. 55, no. 5, pp. 3503–3568, 2022.

- [3] G. Audemard, J.-M. Lagniez, P. Marquis, and N. Szczepanski, “Computing abductive explanations for boosted trees,” in *Proceedings of the International Conference on Artificial Intelligence and Statistics*, PMLR, 2023, pp. 4699–4711.
- [4] R. Koitz-Hristov and F. Wotawa, “Applying algorithm selection to abductive diagnostic reasoning,” *Applied Intelligence*, vol. 48, no. 11, pp. 3976–3994, 2018.
- [5] A. H. de Souza Júnior, “Regional models and minimal learning machines for nonlinear dynamical system identification,” Ph.D. dissertation, Department of Teleinformatics Engineering, Federal University of Ceará, Fortaleza, Brazil, 2014.
- [6] A. Pluska, P. Welke, T. Gärtner, and S. Malhotra, “Logical distillation of graph neural networks,” *arXiv preprint arXiv:2406.07126*, 2024.
- [7] C. Barrett, R. Sebastiani, S. Seshia, and C. Tinelli, “Satisfiability Modulo Theories,” in *Handbook of Satisfiability*, IOS Press, 2009, pp. 825–885.
- [8] L. de Moura and N. Bjørner, “Z3: An efficient SMT solver,” in *Proceedings of the International Conference on Tools and Algorithms for the Construction and Analysis of Systems (TACAS)*, Springer, 2008, pp. 337–340.